

Laporan Tugas 2 Computer Vision : Evaluasi Parameter HOG Menggunakan Sliding Window dan Linear SVM Untuk Deteksi Pedestrian

Annisa Cahyawati (26/591457/PPA/07453)

Link Google Colab : <https://drive.google.com/file/d/1qsC7AtHyX0v5O4g4DpuChffvfmPy3GpV/view?usp=sharing>

Abstrak—Histogram of Oriented Gradients (HOG) merupakan representasi berbasis distribusi orientasi gradien yang banyak digunakan untuk deteksi manusia. Penelitian ini melakukan replikasi sebagian studi parameter Dalal and Triggs dengan menguji pengaruh ukuran sel, jumlah bin orientasi, dan normalisasi blok pada detektor pedestrian berbasis Sliding Window dan Linear SVM. Karena dataset INRIA Person tidak dapat diakses pada pelaksanaan eksperimen, digunakan dataset publik alternatif Maxim37/hazy-pedestrian-detection. Pipeline terdiri atas ekstraksi positive patch dengan context margin, random negative sampling, hard-negative mining satu putaran, HOG, Linear SVM, sliding-window multi-skala, greedy non-maximum suppression (NMS), serta evaluasi AP@0.5 dan kurva miss rate terhadap false positives per window (FPPW). Pada 143 citra uji, konfigurasi 8×8 cell, 6 orientation bins, dan L2-Hys memberikan AP@0.5 tertinggi sebesar 0,1760, sedangkan baseline 8×8, 9 bins, L2-Hys memperoleh 0,1467. L2-Hys juga mengungguli L2, sementara pengurangan ukuran cell menjadi 6×6 dan 4×4 menurunkan AP. Hasil ini menunjukkan bahwa ranking konfigurasi pada dataset alternatif tidak sepenuhnya mengikuti kecenderungan parameter yang dilaporkan dalam paper dan performa detektor masih dibatasi oleh false positive serta false negative.

Kata Kunci : HOG, sliding window, pedestrian detection, Linear SVM, AP@0.5, FPPW, hard-negative mining

I. PENDAHULUAN

A. Latar Belakang

Dalal and Triggs memperkenalkan HOG sebagai deskriptor untuk *human detection* dengan memanfaatkan distribusi orientasi gradien pada wilayah lokal citra. Studi parameter mereka menunjukkan bahwa konfigurasi descriptor berpengaruh terhadap performa deteksi, termasuk jumlah orientation bins, normalisasi blok, *overlap descriptor*, serta ukuran cell dan block [1]. *Paper* tersebut secara khusus melaporkan bahwa peningkatan jumlah bin orientasi memberikan peningkatan performa sampai sekitar 9 bins pada rentang 0°–180°, sementara normalisasi lokal yang efektif seperti L2-Hys berperan penting dalam ketahanan terhadap variasi iluminasi dan kontras [1].

B. Rumusan Masalah

Penelitian ini menguji tiga pertanyaan.


1. Apakah perubahan ukuran cell, jumlah *orientation bins*, dan skema normalisasi blok menghasilkan perbedaan AP@0.5 yang konsisten?
2. Apakah ranking performa antar konfigurasi pada dataset yang digunakan mengikuti kecenderungan yang dilaporkan Dalal dan Triggs? (3) Pada kondisi citra seperti apa detektor HOG mengalami false positive dan false negative?

C. Tujuan

Tujuan penelitian adalah mengimplementasikan pipeline Sliding Window, HOG dan Linear SVM yang dapat diproduksi, melakukan partial replication studi parameter HOG, dan menganalisis hasil melalui AP@0.5, kurva miss rate dan FPPW, biaya komputasi, dan *failure cases*.

II. USULAN METODE

Penelitian menggunakan detektor pedestrian berbasis HOG dan Linear SVM. Citra training digunakan untuk membentuk positive patches dan negative patches, dilanjutkan dengan satu putaran hard-negative mining. Tidak digunakan model deep learning atau transfer learning.



Gambar 1. Flowchart Metode

A. Dataset dan Pembagian Data

Eksperimen menggunakan dataset publik Maxim37/hazy-pedestrian-detection yang tersedia melalui Hugging Face Datasets [2]. Dataset menyediakan citra pedestrian dan bounding box. Pada run yang dilaporkan, digunakan 1.052 data training dan 143 citra test. Total anotasi pada test set yang digunakan dalam evaluasi adalah 245 pedestrian. Dataset ini dipilih sebagai alternatif karena INRIA Person tidak dapat diakses selama eksperimen. Perbedaan domain, terutama adanya kondisi berkabut/hazy dianggap sebagai keterbatasan ketika membandingkan hasil dengan paper [1].

B. Deskriptor HOG

Ukuran *detection window* ditetapkan 64×128 piksel. HOG dihitung menggunakan cells per block 2×2, *orientation bins unsigned* pada rentang 0°–180°, *block normalization* sesuai konfigurasi eksperimen, dan transformasi akar kuadrat. *Baseline* menggunakan cell 8×8, 9 bins, dan L2-Hys sehingga menghasilkan 3.780 fitur. Secara konseptual, gradien horizontal dan vertikal dihitung sebagai.

$$g_x = I(x+1,y) - I(x-1,y), \quad g_y = I(x,y+1) - I(x,y-1) \\ m = \sqrt{g_x^2 + g_y^2}, \quad \theta = \text{atan2}(g_y, g_x) \bmod 180^\circ$$

Magnitudo gradien menjadi bobot histogram orientasi. Histogram pada beberapa cell kemudian digabungkan dan dinormalisasi pada tingkat block sebelum digunakan oleh Linear SVM. Implementasi ini menggunakan struktur HOG yang sejalan dengan simulasi kelas, tetapi *pipeline* training dan dataset berbeda.

C. Training dan Hard-Negative Mining

Positive *patches* diperoleh dari *bounding box* pedestrian dengan context margin 20% dan penyesuaian aspek rasio menuju window 64×128. Digunakan hingga 2.000 *positive patches* dan 2.000 *random negative patches*. *Negative patches* diambil secara acak dari citra training dengan IoU terhadap seluruh ground truth kurang dari 0,05. Classifier adalah Linear SVM dengan C=0,01, *class weight balanced*, dan *random state* 42. Setelah model awal dilatih, dilakukan satu putaran hard-negative mining pada data training dengan mengambil *false positives* berskor tinggi dari sebagian citra training, lalu model dilatih ulang. Jumlah hard negatives pada enam konfigurasi berada pada kisaran 288–383.

D. Sliding Window dan NMS

Deteksi menggunakan multi-scale pyramid pada skala 1,00 dan 0,80 untuk menjaga runtime tetap praktis. Sliding window berukuran 64×128 menggunakan stride 16 piksel pada pipeline yang dilaporkan. Kandidat diberi skor menggunakan decision function Linear SVM dan kemudian disaring dengan *greedy* NMS. Dalam implementasi ini digunakan *greedy* NMS dengan ambang IoU 0,50. *Post processing* tidak direplikasi secara identik dengan keseluruhan implementasi paper, terutama dalam detail parameterisasi dan pipeline evaluasi.

E. Evaluasi

AP@0.5 dihitung dengan mencocokkan detection terhadap ground truth menggunakan IoU $\geq 0,5$. Setiap ground-truth hanya dapat dipasang satu kali. Kurva miss rate terhadap FPPW dihitung dari raw candidate detections sebelum NMS. Karena candidate disimpan hingga TOPK_PER_IMAGE=300 untuk menjaga penggunaan memori dan runtime, FPPW pada implementasi ini merupakan FPPW terhadap candidate windows yang dipertahankan, bukan exhaustive count seluruh sliding window. Perbedaan ini dicatat secara eksplisit sebagai keterbatasan evaluasi.

III. SETUP EKSPERIMEN

A. Desain Eksperimen

Karena *hard negative* mining dilakukan secara independen untuk setiap konfigurasi, jumlah hard negative berbeda antar-eksperimen. Dengan demikian, perbandingan terutama merefleksikan performa pipeline pada konfigurasi HOG yang diuji, bukan eksperimen satu-variabel yang sepenuhnya terisolasi. Baseline menggunakan 8×8 cell, 9 bins, dan L2-Hys. Tiga konfigurasi memvariasikan cell size, dua konfigurasi memvariasikan orientation bins, dan satu konfigurasi membandingkan normalisasi L2 dengan baseline L2-Hys. Seed ditetapkan 42 pada proses sampling dan model.

Tabel 1. Hasil studi parameter HOG dan AP@0.5.


Config.	Cell/Bins	Norm.	Feature Dim.	Train (s)	Detection (s)	AP@0.5
Bins-6	$8 \times 8 / 6$	L2-Hys	2520	138.13	16.21	0.176
Baseline	$8 \times 8 / 9$	L2-Hys	3780	162.16	17.17	0.1467
Bins-12	$8 \times 8 / 12$	L2-Hys	5040	143.0	17.73	0.1303
Norm-L ₂	$8 \times 8 / 9$	L2	3780	106.63	12.75	0.106
Cell-6	$6 \times 6 / 9$	L2-Hys	6480	196.94	22.95	0.105

Seluruh eksperimen dijalankan menggunakan Python pada Google Colab dengan seed 42. Dependency utama mencakup NumPy, Pandas, scikit-image, scikit-learn, Joblib, Pillow, dan Hugging Face Datasets. Notebook menyediakan sel pengunduhan data, konfigurasi parameter, training, evaluasi, visualisasi, dan penyimpanan hasil CSV sehingga eksperimen dapat dijalankan ulang dari awal.

IV. HASIL

A. AP@0.5


Konfigurasi Bins-6_L2Hys memperoleh AP@0.5 tertinggi sebesar 0,1760, diikuti baseline 0,1467 dan Bins-12_L2Hys 0,1303. Norm-L2 memperoleh 0,1060, Cell-6_L2Hys 0,1050, sedangkan Cell-4_L2Hys menjadi yang terendah dengan 0,0761. Dengan demikian, konfigurasi 6 bins memberikan peningkatan AP sekitar 20,0% secara relatif dibanding *baseline*.



Gambar 2. Grafik batang perbandingan AP@0.5 HOG configuration

B. Miss Rate dan FPPW

Kurva DET menunjukkan keenam konfigurasi memiliki pola yang relatif berdekatan. Miss rate terendah yang terlihat sekitar 0,58, yang setara dengan recall maksimum sekitar 0,42. Tidak terdapat satu konfigurasi yang secara konsisten dominan pada seluruh rentang FPPW, sehingga perbedaan parameter HOG pada dataset ini belum mampu mengatasi keterbatasan recall secara keseluruhan.




Gambar 3. Grafik perbandingan Miss Rate dan FPPW

Kurva miss rate dan FPPW pada penelitian ini digunakan terutama untuk membandingkan kecenderungan relatif antara konfigurasi. Karena hanya hingga 300 candidate per citra yang dipertahankan, nilai FPPW tidak merepresentasikan exhaustive sliding-window count seperti pada evaluasi paper.

C. Failure Case

Failure-case analysis menunjukkan adanya *false positive* dan *false negative* yang tinggi. Image 2 memiliki 6 ground-truth dengan 1 TP dan 5 FN; image 7 memiliki 2 ground-truth tetapi 0 TP dan 58 FP, image 10 memiliki 4 ground-truth, 2 TP, 2 FN, dan 17 FP. Kondisi tersebut memperlihatkan bahwa detector masih menghasilkan banyak candidate box pada area background atau area sekitar pedestrian.



Gambar 4. Contoh failure cases; kiri : ground truth, kanan : prediksi Bins-6_L2Hys.

V. ANALISIS HASIL

A. Perbandingan dengan Klaim Paper

Hasil tidak sepenuhnya mengkonfirmasi klaim parameter Dalal and Triggs. Pada paper, peningkatan orientation bins dilaporkan meningkatkan performa hingga sekitar 9 bins dan kemudian cenderung jenuh [1]. Pada eksperimen ini justru diperoleh urutan 6 bins (0,1760) > 9 bins (0,1467) > 12 bins (0,1303). Dengan demikian, kecenderungan tersebut tidak muncul pada dataset alternatif yang digunakan. Perbedaan dapat dipengaruhi oleh dataset, kondisi visual hazy, jumlah data, strategi training, dan detail pipeline yang tidak identik dengan paper.

B. Pengaruh Cell Size

Perbandingan cell size pada penelitian ini menggunakan block 2×2 untuk seluruh konfigurasi, sedangkan studi Dalal and Triggs mengevaluasi kombinasi cell size dan block size. Oleh karena itu, hasil cell-size pada penelitian ini merupakan partial replication dan tidak dapat dibandingkan satu-ke-satu dengan konfigurasi terbaik paper.

C. Pengaruh Orientation Bins

Enam bins memberikan hasil terbaik pada eksperimen. Salah satu penjelasan yang mungkin adalah bahwa representasi yang lebih sederhana cukup untuk menangkap struktur kontur pedestrian pada dataset ini, sedangkan jumlah bin yang lebih tinggi tidak memberikan informasi tambahan yang cukup dan dapat membuat representasi lebih spesifik terhadap variasi citra. Penjelasan ini merupakan interpretasi dari hasil eksperimen, bukan klaim universal.

D. Pengaruh Normalisasi

L2-Hys menghasilkan AP 0,1467, sedangkan L2 menghasilkan 0,1060. Peningkatan relatif sekitar 38,5% menunjukkan bahwa hysteresis clipping dan normalisasi ulang pada block membantu representasi menjadi lebih robust terhadap variasi lokal. Temuan ini lebih konsisten dengan paper yang menyatakan bahwa local contrast normalization sangat penting untuk performa HOG [1].

E. Efisiensi Komputasi

Cell 4×4 menghasilkan 16.740 fitur, lebih dari empat kali dimensi baseline, membutuhkan sekitar 430,02 s untuk training serta 48,86 s untuk detection pada run yang dilaporkan. Baseline menggunakan 3.780 fitur dengan 162,16 s training dan 17,17 s detection. Ini menunjukkan bahwa descriptor yang lebih rinci meningkatkan beban komputasi secara nyata, tetapi tidak meningkatkan AP pada dataset ini.

F. Interpretasi Failure Cases

Pada citra berkabut dan citra dengan beberapa pedestrian, gradient/edge pattern pada background dapat menyerupai bentuk manusia. Akibatnya SVM memberikan skor positif pada banyak window yang tidak benar. Di sisi lain, pedestrian dengan visibilitas rendah, ukuran kecil, atau posisi yang berbeda dari pola training dapat menghasilkan skor yang tidak cukup tinggi sehingga menjadi false negative. Failure cases ini menjelaskan mengapa miss rate tetap tinggi meskipun beberapa konfigurasi memberikan AP yang lebih baik.

VI. KESIMPULAN DAN KETERBATASAN

Eksperimen partial replication HOG menunjukkan bahwa konfigurasi terbaik pada dataset yang digunakan adalah 8×8 cell, 6 orientation bins, dan L2-Hys dengan AP@0.5 sebesar 0,1760. Baseline 8×8, 9 bins, L2-Hys memperoleh 0,1467. Hasil orientation-bin tidak mengikuti kecenderungan Dalal and Triggs, sedangkan keunggulan L2-Hys terhadap L2 lebih konsisten dengan paper. Ukuran cell yang lebih kecil meningkatkan feature dimension dan waktu komputasi tanpa meningkatkan AP. Oleh karena itu, pertanyaan penelitian dapat dijawab bahwa ranking konfigurasi bergantung pada dataset dan pipeline, dan tidak sepenuhnya identik dengan paper.

Keterbatasan utama adalah penggunaan dataset alternatif dengan domain berbeda dari INRIA Person, approximate candidate set untuk kurva FPPW karena TOPIK_PER_IMAGE dan keterbatasan hard-negative mining hanya satu putaran. Pengembangan berikutnya dapat menggunakan dataset INRIA bila akses tersedia, HOG feature map yang dihitung sekali per scale

untuk efisiensi, sweep overlap/stride yang lebih sistematis, dan hard-negative mining multi-round.

REFERENSI

- [1] N. Dalal and B. Triggs, "Histograms of Oriented Gradients for Human Detection," in Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR), 2005, pp. 886–893, doi: 10.1109/CVPR.2005.177.
- [2] [2] Maxim37, "hazy-pedestrian-detection," Hugging Face Datasets. [Online]. Available: <https://huggingface.co/datasets/Maxim37/hazy-pedestrian-detection> Accessed: Oct. 8, 2026.
- [3] [3] W. Zhu, H. Sun, and C. Chen, "Linear Support Vector Machines," scikit-learn documentation, [Online]. Available: <https://scikit-learn.org/>. Accessed: Oct. 8, 2026.